

Contre-audit Force Tracker

État réel après la nuit du 23 au 24 août 2026 — versions **ft-v986** · **ft-v987** · **ft-v988**

Document destiné à une relecture extérieure (ChatGPT). Rédigé par Claude, à la demande de Michel. Tout ce qui suit est **mesuré dans le code exécuté**, sauf mention explicite du contraire. Le dépôt `michdu75-commits/forcetracker` reste la source de vérité : une affirmation de ce document qui contredirait le code a tort.

1. Ce que ce document est, et ce qu'il n'est pas

Ce n'en est pas un de plus. Un audit extérieur de 200 pages a été rendu le 23/08 sur ft-v978. Il a été confronté au code point par point ; le score complet vit dans `docs/SUIVI-AUDIT.md`. Ce document-ci répond à une seule question : **qu'est-ce qui a changé depuis, et qu'est-ce qui reste ?**

Il sépare volontairement trois statuts, parce que les mélanger est la première cause de mauvaise décision : **mesuré** (une exécution le prouve) · **à reproduire** (plausible, non démontré) · **non vérifié** (on ne sait pas, et on le dit).

2. Ce qui a été corrigé cette nuit

Version	Le défaut, et pourquoi il comptait
ft-v986	Six fixtures de test calculaient le jour en UTC alors que l'app le calcule en heure locale. Entre 22 h UTC et minuit, « demain » en UTC vaut « aujourd'hui » à Paris. Deux témoins sont passés au rouge tout seuls à 00 h 34, sans qu'aucun code applicatif n'ait bougé. L'app était juste ; les témoins mentaient — verts 22 heures par jour, rouges 2 heures. Une seule des six fixtures rougissait ce soir-là : les cinq autres étaient latentes.
ft-v987	Les quatre chemins de code-barres s'enregistraient tous comme un « scan ». Caméra, photo décodée localement, photo lue par l'IA et <i>chiffres tapés au clavier</i> partageaient la même provenance. Conséquence mesurable : sur les 23 entrées réelles du journal alimentaire de Michel, les « 6 scans » comptaient des saisies clavier — la donnée censée trancher les questions produit était fausse.
ft-v988	L'export était tout-ou-rien. Le bouton « Exporter » emportait bilan sanguin, bilan corporel, traitement et profil santé, et la fenêtre n'avertissait que pour les conversations. Or ce fichier existe <i>pour être donné</i> . Ajout d'un export restreint à l'entraînement, et l'export complet dit désormais ce qu'il contient.

3. Les trois trouvailles que personne n'avait signalées

3.1 — Le bloc « personnel » envoyé à Milo est générique à 92 %

Méthode : trois profils volontairement opposés (un homme confirmé avec historique ; une femme débutante sans aucune séance ; un homme de 61 ans *avec une tendinite d'épaule et un entraînement à domicile*), comparaison **ligne à ligne** du bloc personnel. Une ligne n'est déclarée générique que si elle est présente telle quelle chez les trois.

Sur ~21 200 caractères facturés par personne, à chaque message	car.	part
identiques chez les trois → strictement génériques	13 452	63 %
dépendent du lieu d'entraînement (le catalogue d'exercices — 5 variantes, pas N)	~6 000	28 %
vraiment personnels (prénom, séances, records, statut)	~1 700	8 %

Le point qui change le correctif : le plus gros morceau — le catalogue d'exercices, ~11 600 caractères — **n'est pas générique**. Il est filtré par le lieu déclaré (salle · salle basique · maison · sans matériel · non renseigné). Le verser dans le bloc commun le rendrait **faux** pour qui s'entraîne dans son salon. Il lui faut **sa propre coupure de cache : cinq entrées partagées**, pas une par personne.

Au passage, deux de mes propres mesures étaient fausses avant d'être bonnes, et c'est écrit dans le dépôt :

① j'ai comparé deux relevés à travers une frontière qui avait bougé entre-temps (« le bloc a été multiplié par 5 » — calcul juste, conclusion trompeuse) ; ② j'ai d'abord classé le catalogue « 100 % générique » en réglant le mauvais champ, ce qui donnait 19 541 au lieu de 13 452. *Un levier qui n'est pas celui que le code lit produit une mesure propre et fausse.*

3.2 — Le plafond de taille est déjà franchi, et le garde-fou ne pouvait pas le voir

Profil	bloc commun	plafond 46 500
en bonne santé	45 362	respecté
avec une tendinite déclarée	47 118	dépassé de 618

Une blessure déclarée injecte des consignes de protection **dans le bloc commun**. Le test automatique utilisait trois profils en bonne santé : il restait donc vert pendant que le plafond était franchi en production chez toute personne blessée. **Le seuil n'a pas été relevé** — c'est explicitement déconseillé dans le code (« il mérite une relecture dédiée, pas un relèvement de seuil de plus »). L'état actuel est **épinglé** pour qu'il ne dérive pas pendant que la décision de fond attend.

3.3 — Un correctif qui n'atteignait pas la donnée, dans la fonction qui documente ce piège

La fonction qui écrit la provenance d'un aliment construit une **liste blanche** de champs. Le drapeau « code-barres douteux » posé en amont s'y arrêta et **n'atteignait jamais l'entrée enregistrée** — sans erreur, sans test rouge. C'est la deuxième fois au même endroit : la première, en août, c'était l'état cru/cuit. **Ce sont les témoins qui l'ont attrapé, pas la relecture.**

4. Ce qui reste — par palier

Avant une ouverture large

- **Un point de refus unique avant de lancer une séance** — vérifier au même endroit les exercices refusés, la zone blessée et les doublons. Aujourd'hui ces vérifications existent mais sont dispersées.
- **Rendre « ne me remets plus cet exercice » réellement opposable** : la consigne tient tant que le modèle la suit, rien ne l'impose côté code.
- **La décision sur le plafond du bloc commun** (§3.2 ci-dessus) : alléger, déplacer, ou relever ?

Après la mise en production

- **Le reclassement des 13 452 caractères génériques** vers le bloc commun — à information constante. ⚠ Il porterait le bloc commun à ~58 800, donc il dépend de la décision ci-dessus.
- **La coupure de cache propre au catalogue** (5 variantes partagées) — plus gros gain, plus gros risque.
- **Relever les compteurs de tokens réels** avant/après. **C'est la seule mesure qui dira si tout cela rapporte quoi que ce soit.**

- Deux conventions de sexe opposées coexistent dans le code (un profil abîmé serait calculé comme l'un et plafonné comme l'autre) — demande de décider ce que « inconnu » veut dire.
- Sommeil et nombre de pas sont reçus, stockés, synchronisés, et **jamais lus**.

5. Ce qui est écarté, avec la raison

Sujet	Pourquoi
« Le PDF de Milo est vide »	Mesuré intact (9 769 caractères sur 9 769). C'était la <i>livraison</i> — un titre passé à la feuille de partage iOS, qui gardait le titre et jetait le fichier.
« Le retrait du bac à sable a créé un trou de sécurité »	Faux : essai jamais promu . Et en le promouvant on a découvert <i>pourquoi</i> il dormait — 7 faux positifs sur 9 phrases anodines. Le promouvoir tel quel aurait été pire que de ne rien faire.
« Conflit de moteurs sur les glucides »	Aucune variable glucidique n'est modifiée par la phase. C'est un conflit de <i>discours</i> , pas de moteurs.
Pipeline OCR + parsers par fabricant	Différé faute de volume (5 imports en un mois). Une architecture dimensionnée pour 1 000 imports qu'on n'a pas est une dette.

6. Ce qui n'est PAS vérifié — et qu'il ne faut pas déduire de ce document

- ① **Les tokens et le coût réel**. Aucune clé API dans l'environnement d'analyse. Tout est en **caractères**. **70 000 caractères ≠ 70 000 tokens**, et chaque message ne repaie pas l'intégralité du contexte.
- ② **Le gain d'un reclassement de cache**. Il dépend du nombre de personnes qui discutent dans la même fenêtre. Avec une poignée de testeurs, il peut être nul.
- ③ **La qualité des réponses après déplacement**. Déplacer du texte change sa **position** dans le prompt. Les tests déterministes prouvent qu'une règle est *présente*, jamais qu'elle est *suivie*. Seul un A/B sur le vrai modèle répondrait — et il coûte des appels.
- ④ **L'échec de partage iOS lui-même**. Le correctif vient d'un cas qui a marché une fois ; l'échec n'a pas pu être reproduit ici (il demande un vrai Safari iOS).

7. Le banc d'essai de Milo

Le benchmark passe de **16 à 21 scénarios**. Les cinq ajoutés viennent tous d'incidents **vécus en salle**, aucun n'est inventé : represcrire pour demain ce qui a été fait aujourd'hui · un temps de repos inexécutable sur une série lourde · une charge au-dessus de ce que le record connu permet de tenir · une variation de balance à 24 h lue comme un changement de tissu · la récitation du contexte système.

Deux principes de ce banc d'essai, à connaître avant d'en lire un rapport : il n'y a aucun juge automatique — un attendu qui ne se vérifie pas par du code reste au jugement humain ; et **un vert vaut moins qu'un rouge**. Un rouge est une preuve ; un vert dit seulement « aucune violation détectable ». On ne conclut jamais « Milo respecte ses règles » d'une passe toute verte.

8. Les questions ouvertes — c'est là qu'un regard extérieur sert

- **Le plafond de taille protège contre la dilution, pas contre le prix.** Si on y verse 13 452 caractères de plus, que devient-il ? Le relever une fois de plus est déconseillé dans le code lui-même. **Existe-t-il une troisième option ?**
- **À partir de combien d'utilisateurs** cinq entrées de cache partagées battent-elles N entrées personnelles ? En dessous, le travail ne rapporte rien.
- **Les records ne sont bornés par rien** : ~41 caractères par record, à vie. Quelqu'un qui suit 200 exercices ajoute ~8 000 caractères à *chacun* de ses messages. Couper mal ferait oublier un record réel à Milo, ce qui coûte plus cher que les caractères. **Quelle règle de sélection serait défendable ?**
- **Faut-il une règle de récupération par groupe musculaire ?** Milo repropose parfois pour demain ce qui a été fait aujourd'hui. La séance du jour est dans son contexte, datée « aujourd'hui » — mais aucune règle ne lui dit quoi en faire. On lui reproche donc de ne pas suivre une consigne qu'on ne lui a jamais donnée.

Force Tracker — contre-audit du 24/08/2026, versions ft-v986 à ft-v988. Suites de tests au moment de la rédaction : parcours 1 295 · calculs 266 · muscles 241 · croisés 50 · dates 7 · Milo 10 · données 102 classées, 0 trou. Documents de référence dans le dépôt : [docs/SUIVI-AUDIT.md](#) (le score), [docs/AUDIT-CONTEXTE-MILO.md](#) §14 (les mesures de contexte), [docs/REPONSE-GPT-CONTEXTE-CACHE.md](#) (la cartographie détaillée).